

Análisis y Reporte sobre el desempeño del modelo

Yael Michel García López (A01750911)

Inteligencia artificial avanzada para la ciencia de datos | 2026-09-16

Modelo: Random Forest (scikit-learn) | Datos: Spaceship Titanic (Kaggle)

Indicador	Sin regularizar	Regularizado	Cambio
Exactitud en prueba	78.38%	80.56%	+2.19 pts
Brecha entrenamiento - validación	19.01 pts	7.28 pts	-11.73 pts
Grado de sesgo	BAJO	MEDIO	
Grado de varianza	ALTA	MEDIA	
Nivel de ajuste	OVERFITTING	AJUSTE ADECUADO	

1. Separación en entrenamiento, validación y prueba

Conjunto	Filas	% del total	Transportados	Uso
Entrenamiento	5215	60.0%	50.35%	Ajustar el modelo
Validación	1739	20.0%	50.37%	Decidir y diagnosticar
Prueba	1739	20.0%	50.37%	Reportar (una sola vez)

La partición es 60/20/20, estratificada por la clase y con semilla 42. La proporción de transportados queda prácticamente idéntica en los tres conjuntos, así que las métricas son comparables entre ellos.

Se usan tres conjuntos y no dos porque validación y prueba cumplen papeles distintos. Validación se consulta muchas veces: con ella se comparan las 96 combinaciones de hiperparámetros, se trazan las curvas y se calculan los diagnósticos. Prueba se mide una sola vez al final, con los hiperparámetros ya congelados. Elegir mirando prueba inflaría el resultado reportado.

La partición se hace antes de cualquier transformación, y todo el preprocesamiento vive dentro de un Pipeline que se reajusta solo con datos de entrenamiento. Así no hay fuga de información.

2. Modelo de partida: Random Forest sin regularizar

Para diagnosticar hace falta un punto de partida donde el problema sea medible, así que el primer modelo se entrena con todos los frenos desactivados. El resultado es un bosque muy grande: 687 hojas por árbol para 5215 ejemplos de entrenamiento, es decir capacidad de sobra para memorizar casos individuales.

Hiperparámetro	Valor	Hiperparámetro	Valor
max_depth	None	max_features	None
min_samples_leaf	1	ccp_alpha	0.0
min_samples_split	2	n_estimators	200

Métrica	Entrenamiento	Validación	Brecha
Exactitud	96.76%	77.75%	19.01 pts
Error	3.24%	22.25%	

3. Diagnóstico del grado de sesgo

El sesgo se mide con el error de entrenamiento: si el modelo no ajusta ni los datos que ya vio, le falta capacidad. Los umbrales se declaran antes de medir: menor a 5% es bajo, entre 5% y 15% medio, mayor a 15% alto.

Grado de sesgo (modelo sin regularizar): BAJO
Error de entrenamiento = 3.24%, muy por debajo del umbral de 5%.


Un sesgo bajo descarta el underfitting, pero no significa que el modelo sea bueno: el error de entrenamiento es bajo porque el modelo memorizó. De hecho queda por debajo del error irreducible estimado del problema (19%), lo cual ya indica que está ajustando ruido. En validación el error sube a 22.25%.

4. Diagnóstico del grado de varianza

La varianza se mide con la brecha entre el error de validación y el de entrenamiento. Umbrales: menor a 3 puntos es baja, entre 3 y 10 media, mayor a 10 alta.

Grado de varianza (modelo sin regularizar): ALTA

96.76% en entrenamiento contra 77.75% en validación, es decir 19.01 puntos de brecha: casi el doble del umbral de 10 puntos.



El panel izquierdo muestra el patrón del sobreajuste: entrenamiento pegado al techo y validación muy por debajo, con una franja que nunca se cierra. La brecha baja de 23.5 puntos con 260 muestras a 19.0 con 5215, así que más datos ayudan pero muy despacio. Las curvas de validación y prueba van juntas en los dos paneles, lo que confirma que la partición es representativa; la de prueba se grafica solo para el reporte y ninguna decisión se tomó mirándola.

Muestras	Entrenamiento	Validación	Prueba	Brecha
260	99.62%	76.14%	77.06%	23.48 pts
521	98.66%	74.81%	77.52%	23.84 pts
1043	97.99%	76.48%	79.36%	21.51 pts
2086	98.18%	76.71%	77.46%	21.47 pts
3129	97.76%	77.40%	78.44%	20.36 pts
4172	97.05%	78.55%	79.30%	18.50 pts
5215	96.76%	77.75%	78.38%	19.01 pts

5. Diagnóstico del nivel de ajuste


Sesgo	Varianza	Diagnóstico	Significado
Alto	Baja	Underfitting	Modelo muy simple, falla parejo
Bajo	Alta	Overfitting	Memorizó el entrenamiento
Alto	Alta	Mal planteado	Revisar variables y datos
Bajo/Medio	Baja/Media	Ajuste adecuado	Generaliza bien

Nivel de ajuste (modelo sin regularizar): OVERFITTING

Sesgo bajo con varianza alta. Hay tres evidencias que coinciden: el error de entrenamiento de 3.24%, la brecha de 19.01 puntos y unas curvas de aprendizaje que nunca convergen.

6. Técnicas de regularización aplicadas

Se evaluaron cuatro técnicas, cada una atacando el sobreajuste por una vía distinta. Para cada una se trazó una curva variando un solo hiperparámetro y midiendo entrenamiento contra validación.



La línea verde punteada marca el valor con mejor exactitud en validación.

Técnica	Mejor valor	Validación	Brecha	Qué hace
max_depth	8	78.95%	6.53 pts	Limita qué tan específicas son las reglas
min_samples_leaf	5	79.47%	9.48 pts	Evita hojas construidas sobre casos aislados
max_features	0.4	79.93%	7.28 pts	Diversifica los árboles del bosque
ccp_alpha	0.001	79.36%	4.11 pts	Penaliza el número de hojas


La curva de ccp_alpha es la más clara de las cuatro: la exactitud en entrenamiento cae de 96.76% a 78.85% mientras la de validación primero sube y luego baja, dibujando el compromiso sesgo-varianza completo.

La curva de max_features se trazó sobre la base ya regularizada, a diferencia de las otras tres. Medida sobre el modelo sin frenos sale plana, porque con profundidad ilimitada y hojas de un ejemplo el árbol memoriza sin importar cuántas variables vea. Solo funciona combinada, no como remedio aislado.

7. Modelo regularizado: comparación antes y después


Se armó una rejilla de 96 combinaciones y se evaluaron todas contra validación. El criterio fue mayor exactitud en validación y, en caso de empate práctico, la configuración más simple. El conjunto de prueba no participó.

Hiperparámetro	Antes	Después
max_depth	None	16
min_samples_leaf	1	5
max_features	None	0.4
ccp_alpha	0.0	0.0



Métrica	Sin regularizar	Regularizado	Cambio
Exactitud entrenamiento	96.76%	87.21%	-9.55 pts
Exactitud validación	77.75%	79.93%	+2.19 pts
Exactitud prueba	78.38%	80.56%	+2.19 pts
Brecha entrenamiento - validación	19.01 pts	7.28 pts	-11.73 pts
ROC-AUC prueba	0.8734	0.8877	+0.0144
F1 prueba	0.7806	0.8088	+0.0282
Sensibilidad prueba	0.7637	0.8162	+0.0525
Hojas por árbol	687	290	-396

La exactitud en entrenamiento bajó 9.55 puntos, y eso es justamente lo que se buscaba: regularizar consiste en renunciar a desempeño sobre los datos vistos para ganarlo sobre los nuevos. El intercambio fue favorable, +2.19 puntos en prueba, y además con un modelo 58% más simple.



Los falsos negativos bajan de 207 a 161, y por eso la sensibilidad sube de 0.7637 a 0.8162. El ROC-AUC mejora de 0.8734 a 0.8877, lo que indica que las probabilidades estimadas son más informativas.

8. Diagnóstico del modelo regularizado

Grado de sesgo: MEDIO

Error de entrenamiento = 12.79%, dentro del rango medio. Subió respecto a 3.24%, y eso es esperado: es el precio de la regularización.

Grado de varianza: MEDIA

Brecha = 7.28 puntos contra 19.01 antes, así que bajó del rango alto al medio.

Nivel de ajuste: AJUSTE ADECUADO

Sesgo medio con varianza media: sesgo y varianza moderados, sin evidencia de memorización ni de falta de capacidad.

Que el sesgo pase de bajo a medio no es un empeoramiento, es el mecanismo de la regularización funcionando: reducir la varianza normalmente aumenta el sesgo, y el objetivo no es minimizar ninguno por separado sino el error total en datos nuevos. Ese error bajó de 21.62% a 19.44%. El error de validación final (20.07%) ya está cerca del piso estimado del problema (19%), así que el margen que queda por la vía de regularizar es limitado.

9. Conclusiones

Punto del análisis	Modelo inicial	Modelo final	Evidencia
Separación de datos	60/20/20	igual	Sección 1
Grado de sesgo	BAJO	MEDIO	Error de entrenamiento vs. umbrales
Grado de varianza	ALTA	MEDIA	Brecha y curvas de aprendizaje
Nivel de ajuste	OVERFITTING	AJUSTE ADECUADO	Combinación sesgo-varianza
Regularización	ninguna	3 técnicas	Curvas de complejidad y búsqueda

- El modelo de partida sobreajustaba: sesgo bajo con varianza alta y una brecha de 19.01 puntos.
- Tres técnicas (`max_depth=16`, `min_samples_leaf=5`, `max_features=0.4`) redujeron la brecha a 7.28 puntos y llevaron el diagnóstico de overfitting a ajuste adecuado.
- La exactitud en prueba subió de 78.38% a 80.56% con un modelo 58% más simple.

Quedan dos limitaciones. Los diagnósticos dependen de los umbrales elegidos, y en particular el umbral de sesgo alto (15%) está por debajo del error irreducible estimado (19%), así que sirve para comparar los dos modelos pero no como medida absoluta de capacidad. Y la búsqueda usa una sola partición de validación: la segunda mejor combinación quedó a 0.23 puntos de la primera, dentro del margen de error de muestreo.